

# 基于改进LSTM算法的天地一体化信息网络流量预测

潘成胜<sup>1,2</sup>, 王羽夫<sup>1</sup>, 杨 力<sup>1</sup>

(1.大连大学通信与网络重点实验室, 辽宁 大连 116622 ;

2.南京信息工程大学, 江苏 南京 210044)

**摘 要:** 天地一体化信息网络由于存在流量突发性强、拓扑时变等问题使得通信易产生中断, 流量波动不平稳导致其流量预测难度远高于地面网络。针对该问题, 提出一种改进的LSTM算法, 首先分析流量序列滞后变量对预测值的影响, 判断流量自相关性; 其次, 采用以预测值代替中断的方式, 消除训练集的噪声和断点; 最后, 使用Dropout算法减少了噪声和神经网络过拟合带来的影响, 准确预测天地一体化信息网络流量数据。仿真实验表明, 在OPNET仿真环境中, 该算法相较于其他算法准确性提升了59.21%, 算法训练速度提升了11.11%, 能够为天地一体化信息网络统筹调度提供有效的数据支撑。

**关键词:** 天地一体化信息网络; 网络流量预测; 深度学习; 流量自相关性

**中图分类号:** TN929

**文献标识码:** A

**doi:** 10.11959/j.issn.2096-8930.20200208

## Traffic Prediction of Space-Integrated-Ground Information Network Based on Improved LSTM Algorithm

PAN Chengsheng<sup>1,2</sup>, WANG Yufu<sup>1</sup>, YANG Li<sup>1</sup>

1.Communication and Network Laboratory, Dalian University, Dalian 116622, China

2.Nanjing University of Information Science and Technology, Nanjing 210044, China

**Abstract:** The space-integrated-ground information network is easy to interrupt and the traffic fluctuation is not stable due to the problems of high traffic burst and topological time-varying, which makes the traffic prediction difficult much higher than the ground. In order to solve this problem, an improved LSTM algorithm was put forward. Firstly, the traffic autocorrelation was judged by analyzing the influence of the lag variable of traffic sequence on the predicted value; Secondly, the noise and breakpoint of the training set were eliminated by replacing the interruption with the predicted value; Finally, Dropout algorithm was used to reduce the impact of noise and neural network over fitting, and accurately predict the traffic data of the integrated intelligent network. The simulation results showed that in OPNET simulation environment, compared with other algorithms, the accuracy of this algorithm was improved by 59.21%, and the training speed of the algorithm was improved by 11.11%, which could provide effective data support for the overall scheduling of the integrated intelligent network.

**Keywords:** space-integrated-ground information network, traffic prediction of network, deep learning, traffic autocorrelation

### 1 引言

天地一体化信息网络是将空间轨道卫星、近空飞行器、高空无人机、海基、陆基等节点通过星间链路与星地链路联合, 能够在空、天、地等领域充分融合异构网络, 展现智能信息技术的一种新型网络架构<sup>[1]</sup>。其中流量信息是网络负荷状态的重要反馈指标, 在天地一体化信息网络中, 通过对各个卫星后续时间片的流量进行预测, 根据其流量需求, 可提前对各卫星的流量传输、路

由选择进行统筹和规划, 从而最大限度发挥星上计算机的并行度, 减少并发程序的执行时间, 避免拥塞, 提升路由效率<sup>[2]</sup>。

近年来, 网络流量的预测方法层出不穷, 不同的预测方法在不同的网络环境中发挥了巨大的作用。天地一体化信息网络结构复杂、对流量的预测准确度需求高, 网络拓扑高动态, 网络流量突发性强, 需要即时、准确地从短期和长期两个方面对天地一体化信息网络的流量

**收稿日期:** 2020-10-09; **修回日期:** 2020-11-10

进行预测。天基网络中卫星的运动使得整个网络拓扑一直处于不断变化中。卫星网络节点在链路切换时卫星对地面设备不可见,导致卫星网络会发生周期性中断,此时卫星网络流量会出现“断点”。同时天地一体化信息网络流量数据又具有突发性,在某些时段网络流量会有非周期性突增或突减的情况产生,卫星网络流量也可能因此发生中断。此时对断点的处理不能单单采用取断点前后数据的中间值的方式代替,否则将会影响对突发性流量数据的预测,可见如果不妥善处理这些断点会大大影响预测的精确度和流畅性。因此对流量数据预处理要同时考虑到断点和流量突发性带来的影响,对流量数据的预测要兼顾准确度与速度,达到均衡。

目前,基于普通网络流量的预测模型已经被广泛使用。传统的模型有以下几类:自回归滑动平均模型(Auto-Regressive and Moving Average Model, ARMAM)、差分整合移动平均自回归模型(Auto-Regressive Integrated Moving Average, ARIMA)、马尔可夫模型(Markov Model)等。此类模型结构简单,预测准确度较高,已在普通网络流量预测方面发挥了一定的作用,但是相较于线性预测模型在处理断点多的数据时预测误差率较高,所以此类模型不适用于天地一体化信息网络流量的预测。现在较为流行的基于机器学习神经网络的预测模型崭露头角,表现出了卓越的预测能力。经典的BP神经网络在处理此类流量数据时拥有更高的泛化能力和准确度,现在很多网络流量的预测方法都通过对传统BP网络进行改进使它能够应用于更多类型的网络流量数据。例如参考文献[3]提出了一种基于自适应微分进化(Adaptive Differential Evolution, ADE)算法优化小波神经网络的预测模型(ADE-WNN),通过优化小波神经网络,克服小波神经网络的传统缺陷,提升短期地面网络流量预测的准确度和稳定性。参考文献[4]提出了一种基于深度学习的神经网络,对无线网络的流量进行了预测,通过使用一种深度时空残差卷积神经网络(LA-ResNet)利用注意力机制解决无线网络流量的预测问题。参考文献[5]提出了一种基于小波变换和极限学习机的网络流量预测模型。参考文献[6]提出了一种基于神经网络的网络预测方案,通过将循环神经网络(Recurrent Neural Network, RNN)和门控递归单元(Gate Recurrent Unit, GRU)结合用于网络流量预测,该算法在面对长期时间序列时很难避免RNN自身所带来的梯度消失和梯度爆炸等问题。参考文献[7]提出了一种基于自回归条件持续时间(Autoregressive Conditional Duration, ACD)和粒子滤波器的短期网络流量预测算法。参考文献[8]通过建立改进的BP神经网络模型在对

IPv6的正常网络流量预测中取得了较高的准确率。参考文献[9]提出的基于卷积神经网络(Convolutional Neural Network, CNN)将流量分类预测的方式在面对多序列的网络流量时效果较好,但在单序列的网络流量中几乎无用武之地。

在天地一体化信息网络的流量预测方面,传统的网络流量预测方案需要人工提取特征。人工提取特征依赖于模型设计者的经验和思维缜密度;从算法层面来说,传统算法如ARMA算法、ARIMA算法需要将整个序列代入公式中进行运算,算法复杂度远远大于只提取和保存滞后变量特征的神经网络算法,大多数的机器学习或是深度学习算法虽然在时序预测上有较好的表现,但在经过多次训练后极易容易陷入过拟合的情况,从而容易陷入局部最优和训练速度缓慢的缺陷。很多专家针对卫星网络的流量特征分析<sup>[10-11]</sup>与流量预测方向已经做了很多研究<sup>[12]</sup>,但现有的网络流量预测算法在卫星网络环境中对流量的断点和噪声问题的处理不佳,不适用于神经网络的训练。

本文提出了一种基于改进长短期记忆(Long Short-Term Memory, LSTM)神经网络算法的天地一体化信息网络流量预测方法,首先通过分析流量序列滞后变量对预测值的影响,判断流量自相关度,然后基于经过Dropout算法优化的LSTM,将训练集以断点为节点分段放入该LSTM训练,使用训练后的预测值代替断点来处理训练数据,使训练数据的曲线连续。Dropout算法在每次训练中随机屏蔽一部分隐藏层神经元,减少各隐藏层神经元对流量时间序列训练集的依赖性,避免陷入过拟合的困境,使神经网络在预测时更注重未来时间片的趋势,间接地减少了网络流量中噪声对预测模型的影响,提升了预测的准确度。在对实际网络流量预测的仿真中,相较于上述网络流量预测算法,本文所提出的算法在预测精度上提升了59.21%,算法训练速度提升了11.11%,与经典算法相比有了较好的改善和进步,满足了天地一体化信息网络的预测需求,同时为天地一体化信息网络统筹调度提供有效的数据支撑。

## 2 RNN与LSTM

RNN适用于处理序列数据,即在当前输入与前面输入的数据相关时,RNN往往有着良好的表现。如图1所示<sup>[13]</sup>,这是一个简单的RNN,它由一个输入层、一个隐藏层和一个输出层组成,RNN有一个重复使用的神经元,而这个神经元的权重取值 $s_t$ 不仅取决于当前的输入值 $x$ ,还取决于上一次隐藏层的值 $s_{t-1}$ ,权重矩阵 $W$ 就是记录上一次的隐藏层的值,并作为本次输入的权重参与计

算。由此可知，RNN的输出值是受前面历次输入值影响的，这也是RNN在处理当前数据时可以往前看任意多个输入值的原因。




图1 RNN示意

上述特性使得RNN在处理序列数据时占据了巨大的优势，然而RNN也有缺陷。由于RNN的梯度下降算法是一个指数函数，若指数过大，即参考的输入值过远时，会导致对应误差项的值增长或缩小得非常快，这样就会存在相应的梯度消失或者梯度爆炸问题。

梯度爆炸比较容易处理。当梯度爆炸时会收到一个空值，在这里可以设置一个梯度阈值，当梯度超过这个阈值时可以直接截取；而梯度消失更难检测，处理更难。梯度消失意味着从某一时刻起，梯度几乎已经减少到0，那么从该时刻起再往前走，得到的梯度（几乎为0）都不会对最终的梯度值有任何贡献，这就相当于无论该时刻之前的网络状态是什么也不会在训练中产生影响<sup>[14]</sup>。网络已经忽略了该时刻之前的状态，这也就是为什么原始RNN无法处理长期依赖的原因。

由此，LSTM应运而生。考虑到原始RNN只有一个隐藏层的状态，对短期输入十分敏感。LSTM在隐藏层中加入了一个状态用来保存长期的状态，从而解决了RNN无法处理长期依赖的问题。原始RNN与LSTM的隐藏层对比如图2所示。




图2 原始RNN与LSTM的隐藏层对比

LSTM最大的特点就是使用了“门”的结构，其本质上是3个控制开关，所以又被称作“三重门”。第一个开关称为“遗忘门”，用来决定从细胞状态中丢弃什么样的信息；第二个开关称为“输入门”，用来决定什么状态的值将要被更新；第三个开关被称为“输出门”，其作用是控制长期记忆对当前输出的影响。LSTM整体结构如图3所示。

遗忘门的衰减系数计算公式为

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \tag{1}$$

其中， $\sigma$ 是Sigmoid激励函数， $W_f$ 为“遗忘门”的权值矩




图3 LSTM结构

阵,  $h_{t-1}$ 是上一时刻的“遗忘门”神经元状态,  $x_t$ 是当前时刻的输入值,  $b_f$ 是“遗忘”偏置项。通过读取 $h_{t-1}$ 和 $x_t$ 的数值, 经过Sigmoid激励函数处理之后会输出一个0~1的数值 $f_t$ , 用来决定从细胞状态中丢弃什么信息, 用1表示“完全保留”, 0表示“完全舍弃”。

“输入门”计算公式为

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (2)$$

$$\tilde{c}_t = \tanh(W_c[h_{t-1}, x_t] + b_c) \quad (3)$$

$$c_t = f_t c_{t-1} + i_t \tilde{c}_t \quad (4)$$

首先经过了一层Sigmoid激励函数, 输出了0~1间的值来决定什么样的输入值 $i_t$ 将要被更新,  $b_i$ 为“输入”偏置项。然后经过tanh激励函数筛选出新的候选值 $\tilde{c}_t$ , 计算更新旧神经元的状态, 将上一时刻的神经元状态 $c_{t-1}$ 更新至 $c_t$ 。

这样LSTM神经元的当前记忆 $\tilde{c}_t$ 与长期的记忆 $c_{t-1}$ 结合在一起得到了新的记忆单元 $c_t$ , “遗忘门”可以控制它保存长期信息, “输入门”又可以控制它避免无用的信息进入记忆。

“输出门”的计算公式如下

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (5)$$

$b_o$ 是输出门偏置项, 同理经过了一层Sigmoid激励函数筛选出输出的信息 $o_t$ 。

LSTM最终的输出由“输出门”和前面计算的单元状态 $c_t$ 共同决定, 计算公式如下

$$h_t = o_t \tanh(c_t) \quad (6)$$

得到最后的输出值 $h_t$ 。

### 3 基于改进LSTM的预测模型

#### 3.1 自相关度测试

在网络流量预测中, 流量时间序列的自相似度是单序列中确认需要参考的滞后数据的一个重要指标, 即对于该时间序列的某一采样点, 其前面第 $i$ 个采样点可以用于参考预测出该采样点。考虑数据和一定间隔数据的相关性, 接近1是正相关, 接近-1是负相关, 接近0就代表相关性很低。在确定滞后变量的个数后, 可以此为依据设置LSTM神经网络输入层神经元个数, 在数据预处理中, 将各滞后变量按照时间间隔放在同一个数组中, 方便直接输入神经网络得到预测值。

自相关函数公式为

$$R(n) = \frac{\sum_{i=1}^{n-h} [(x_i - \mu)(x_{i+h} - \mu)]}{\sum_{i=1}^n (x_i - \mu)^2} \quad (7)$$

时间序列的自相关函数其实是若干阶自相关系数的集合,  $n$ 是样本容量,  $h$ 是阶数,  $\mu$ 是该时间序列的均值,  $x_i$

代表各采样点。

通过该流量时间序列的分析, 自相关程度如图4所示。




图4 流量时间序列的自相关程度

图4中, 该时间序列的各采样点与其前两个采样点自相关系数较大, 也就是说对于任意采样点 $i_t$ , 可以通过 $i_{t-1}$ 与 $i_{t-2}$ 两个采样点作为滞后变量预测出 $i_t$ 的值, 如果存在周期性, 设周期为 $T$ , 那么可以通过 $i_{t-1+T}$ 和 $i_{t-2+T}$ 来预测 $i_t$ 的值。若前 $i$ 个采样点与预测点相关性较小, 则需要扩充样本空间找到高自相关度的采样点进行预测。

#### 3.2 数据预处理

数据预处理是为了将源数据转换为易于神经网络训练的形式, 从而提高数据的质量, 提高后续学习和预测的精度。数据预处理将每个特征维度都减去相应的均值实现中心化, 使数据变成零均值, 然后将数据进行标准化和归一化, 即让每个特征维度的最大值和最小值按比例缩放到0~1之间, 这样可以使新数据更接近标准高斯分布, 减小神经网络训练时的压力, 节省训练时间。

由于天地一体化信息网络流量数据存在断点, 这种非线性时间序列若不经处理直接放入神经网络的训练中, 会使训练过程困难, 对神经网络训练时的准确性和流畅度造成影响; 若只取该断点的前后采样点的均值代替断点, 将无法把网络流量的突发性定义为神经网络神经元特征, 因此对训练数据断点的处理就成为了关键。本文提出了一种改进的LSTM模型, 如图5所示。

图5中将训练数据根据断点分片, 记为 $[1, 2, \dots, t]$ 。在训练过程中, 先将标记1放入模型中进行训练, 测试后可以得到一个预测值 $p$ , 来代替标记1与标记2之间的断点值, 然后将标记1、标记2通过该预测值 $p$ 连接到一起成为






图5 断点处理流程

一个新的标记段，继续放入模型中进行训练，直到遍历整个训练集，填补所有的断点。

与断点处理相对应的LSTM模型的架构如图6所示。

图6中，模型的“输入层”可接受任意大小的二维数组 $x$ ，以便于循环训练预测。通过3.2节对该流量时间序列的自相关度计算可知，与预测值 $p$ 自相关度最高的滞后变量有 $m$ 个，所以设置这个模型中输入层作为一个拥有任意长度的二维数组，长度取决于断点之间的间隔，其中第二维度为2；该LSTM模型有两层，主要是对短期的流量时间序列的预测，如果在隐藏层引入过多的神经元会分散序列的特征点，故LSTM的隐藏层神经元个数不宜过多。第一层LSTM隐藏层神经元有20个，经过Dropout层后将数据传入第二层LSTM；第二层LSTM的隐藏层神经元个数也为20个，其作用是将第一层LSTM的输出作为输入再进行一次计算，提升预测的准确度；最后经过一个全连接层输出一个预测值 $p$ 。

该神经网络中Dropout层的作用是通过训练中随机屏蔽一部分神经元，防止神经网络陷入过拟合的境况中。过拟合是在深度学习的模型中模型参数过多、训练样本




图6 LSTM断点处理模型结构

太少，神经元在训练过程中过度地去追求拟合该序列的每一个点，导致该神经网络在训练集中损失函数小、预测精度高，在测试集中损失函数大、预测精度差。因此采用了通过阻止特征检测器的共同作用的方式来提高神经网络的性能，即在每次训练中随机使一部分神经元失效，而在测试时使用所有神经元共同计算和预测，以此减少该神经网络对训练集的依赖性和网络流量时间序列的突发性对神经网络训练带来的影响，使神经网络的泛化能力更强<sup>[15]</sup>。这里将Dropout的参数设置为0.5，也就是在训练中随机屏蔽50%的神经元，以此来达到更优秀的预测效果。

3.3 预测模型的构建与训练

模型结构如图7所示。

由于该预测模型和数据处理模型使用的是同一个数据集，故只需在隐藏层神经元个数上稍作改动即可，在该模型中第一层的LSTM隐藏层有32个神经元，经过Dropout算法后将32个特征传入下一个LSTM隐藏层，第二个LSTM有64个神经元，这样通过两层拥有不同神经元数量的LSTM隐藏层可以对流量时间序列的特征进行细化，提高特征的提取准确度。预测模型在预测时使用了Adam算法对神经网络进行优化，其包含了随机梯度下降算法的优点，同时加入了动量的概念，使得神经网络可




图7 LSTM预测模型

以迅速收敛，波动幅度更小，非常适合网络流量预测这种数据和参数较大的问题。

较为传统的ARIMA算法在地面短时网络流量的预测上一直拥有较为优秀的性能，ARIMA (  $p,d,q$  ) 中  $p$  代表模型中时序数据自身的滞后数， $d$  代表时序数据在几阶差分化后稳定， $q$  代表模型中预测误差的滞后数。计算公式如下

$$\hat{y}_t = \mu + \varphi_1 \times y_{t-1} + \cdots + \varphi_p \times y_{t-p} + \theta_1 \times e_{t-1} + \cdots + \theta_q \times e_{t-q}$$

(8)

其中， $\varphi$  表示  $p$  的系数， $\theta$  表示  $q$  的系数， $e$  表示该项误差系数。

分析式(8)可看出，ARIMA模型需要将所有的滞后系数进行多次计算，其算法复杂度要远高于只保留滞后系数特征的LSTM神经网络。

4 仿真与结果分析

4.1 模型的构建与训练

本次仿真实验使用OPNET仿真软件模拟天地一体化信息网络环境，从铱星星座中选6个卫星和2个地面站模拟天地一体化信息网络。传输数据包通过卫星网络路由，寻找最优路径，传到中继节点，抵达地面站。

在这个模拟网络拓扑中，send节点作为地面基站通信流量的输入端，将地面通信流量传入卫星网络中；中间4个

rcv节点作为移动的卫星路由节点模拟卫星拓扑会随时间改变的情况。rcv\_1节点作为卫星网络中通信流量的输出端，与地面接收基站通信，将通信流量传回地面。从输出端到接收端的最大跳数不超过3跳，超出即视为链路不连通。

在仿真实验开始时，每个节点会根据自身位置以及周围节点位置，判断当前链路的连通性，把可连通链路作为可选链路保存。然后根据可选链路，找出send和rcv\_1之间的连通链路，寻找出最小跳数的链路组成卫星网络拓扑。

每过5 min，卫星网络拓扑可能会因为卫星节点的轨迹运动造成先前连通的链路断开，从而造成卫星拓扑存在环路，即通信流量没法成功地从send节点发送到rcv\_1节点，导致实验无法继续进行。所以需要定时让每个节点向周围节点发送数据包，探测可用链路，实时更新可用链路，让接收端和输出端始终保持连通。在实验中，为了避免因链路无法闭合，卫星节点一直发送探测数据包，流量激增现象的发生，将探测流生存时间设置为1 min，使预测训练不会因为节点探测数据流激增而产生不必要的影响。

为模拟天地一体化信息网络流量特性，随着卫星节点的移动，卫星网络的拓扑结构会随时间变化而变化，所以每个节点都有可能存在断点。本次实验截取了一周的流量数据，并从中选取了120个采样点作为测试，从图8可明显看出在天地一体化信息网络流量中存在断点。经过本文提出的流量数据断点方法处理后结果如图8所示。




图8 断点处理后结果

图8中断点已经通过本文所提出的处理方式由预测值替代，保证了神经网络训练的速度和流畅性，同时提高了神经网络在后续测试时的精确度。仿真实验将选取120


个采样点进行测试,选取前80个采样点作为训练样本,后40个采样点作为预测样本。

## 4.2 仿真评价指标

为能准确评价天地一体化信息网络流量预测的准确度,这里将使用均方根误差(Root Mean Square Error, RMSE)模型、平均绝对误差(Mean Absolute Error, MAE)模型和平均绝对百分比误差(Mean Absolute Percentage Error, MAPE)模型来评价预测准确度。

RMSE模型用来衡量真实值与预测值的偏差,常用来作为机器学习模型预测结果的标准。RMSE的计算公式如下

$$\text{RMSE}(X, h) = \sqrt{\frac{1}{m} \sum_{i=1}^m (h(x_i) - y_i)^2} \quad (9)$$



(a) LSTM算法网络流量预测值

MAE模型是绝对误差的平均值,可以更好地反映预测值误差的实际情况。MAE的计算公式如下

$$\text{MAE}(X, h) = \frac{1}{m} \sum_{i=1}^m |h(x_i) - y_i| \quad (10)$$


MAPE模型可以用来对不同模型同一组数据的预测的评估。当MAPE为0时表示完美模型;为100%时表示劣质模型。MAPE的计算公式如下

$$\text{MAPE}(X, h) = \frac{100\%}{m} \sum_{i=1}^m \left| \frac{h(x_i) - y_i}{y_i} \right| \quad (11)$$


式(9)~式(11)中 $X$ 为输入值, $h$ 为预测函数, $h(x_i)$ 为实际预测值, $y_i$ 为期望预测值, $m$ 为样本容量。

## 4.3 实验结果与分析


BP神经网络与ARIMA时间序列模型因为结构简单、



(b) ARIMA算法网络流量预测值



(c) RNN算法网络流量预测值



(d) 本文改进的LSTM算法网络流量预测值

图9 各算法的网络流量预测结果

精确度较高，常作为经典算法应用在普通网络预测中，很适合用来对比评价一个新模型的性能，但未经优化的BP网络需要较长的训练时间才能提升预测精度。本文选取了RNN算法和普通LSTM算法作为本文算法在智能神经网络方面的对比。实验中将使用LSTM、ARIMA、RNN以及本文提出的算法在相同实验条件下训练1 000次后计算训练时间，预测后通过仿真评价指标对各算法预测结果进行分析，以此客观评价本文算法的训练速度和预测精度。

图9和表1为4种预测结果对比，为避免在仿真实验中偶然性带来的干扰，实验中每个算法运行10次后取平均值作为最后的预测结果。

从图9中各右上小图和表1可以看出，相同的实验环境和训练次数下，在天地一体化信息网络流量的预测方面，得出如下结论。RNN算法由于未经改进，存在梯度消失和梯度爆炸的问题，虽然在上升与下降的趋势上已经有轻微拟合，但在数据的突发阶段无法达到预测要

求，RMSE值为374.53，模型评估为60.77%，训练时间为91 s，模型评估较差。LSTM算法是RNN的改进算法，本文使用了未经改进的单层LSTM算法用以对比，在预测精度上高于RNN，RMSE值为62.14，训练时间为72 s，模型评估为31.52%。ARIMA模型作为离线训练方式无法计算训练时间，RMSE值为37.11，模型评估为11.93%，但因为其作为线性预测模型，需要将所有滞后变量全部纳入计算，其在算法复杂度方面远远高于改进后的LSTM模型，并且在流量时序预测上具有滞后性，不适用于天地一体化信息网络流量预测。本文算法预测效果最好，收敛性最佳，RMSE值为15.33，训练时间最快（为64 s），模型评估为5.35%，在训练中不再追求过度拟合训练数据而是学习其大体趋势，受突发性流量数据影响较小，所得预测结果误差最低。4种算法误差值对比如图10所示。

从图10可知，改进后的LSTM误差最低，与其他算法相比各采样点误差更接近于0，准确度较高。图10中右上角小图显示了面对突发流量数据时各算法的预测误差，改进后的LSTM能更好地适应流量突发的状况，更好地满足天地一体化信息网络流量预测的需要。

5 结束语

本文利用收集到的天地一体化信息网络中卫星网络流量序列提出了一种基于深度学习的断点处理和训练

表1 不同算法效果对比

| 算法类型        | RMSE   | MAPE   | 训练时间/s |
|-------------|--------|--------|--------|
| 本文改进的LSTM算法 | 15.38  | 5.35%  | 64     |
| RNN算法       | 374.53 | 60.77% | 91     |
| ARIMA算法     | 37.71  | 11.93% | —      |
| LSTM算法      | 62.14  | 31.52% | 72     |




图10 4种算法误差值对比



模型来预测天地一体化信息网络中的卫星流量。通过使用预测值替代断点的方式对数据进行预处理，并使用了Dropout算法对神经网络进行优化，从而提升了训练的流畅性和神经网络的精度。仿真实验表明相较于其他经典的网络流量预测算法，本文提出的算法在天地一体化信息网络流量的预测中拥有更高的预测精度和更快的训练速度，但是由于LSTM神经网络使用了独特的“门”，在算法运行所需要的内存上要大于其他算法。可见该算法在天地一体化信息网络系统中拥有较高的使用价值。

## 参考文献：

- [1] 成艳, 韩笑冬, 陈亮亮, 等. 天地一体化信息网络参考模型及关键技术[J]. 空间电子技术, 2017(4): 39-42+47.  
CHENG Y, HAN X D, CHEN L L, et al. Function reference model and key technologies of space-integration ground information network[J]. Space Electronic Technology, 2017(4): 39-42+47.
- [2] 刘立祥. 天地一体化信息网络[M]. 北京: 科学出版社, 2015.  
LIU L X. Space-and-ground integration network[M]. Beijing: Science Press, 2015.
- [3] 林振荣, 黎嘉诚, 杨冬芹, 等. 改进微分进化和小波神经网络的网络流量预测[J]. 计算机工程与设计, 2019, 040(12):3413-3418.  
LIN Z R, LI J C, YANG D Q, et al. Network traffic prediction based on wavelet neural network with improved differential evolution algorithm[J]. Computer Engineering and Design, 2019, 040(12):3413-3418.
- [4] LI M, WANG Y W, WANG Z W, et al. A deep learning method based on an attention mechanism for wireless network traffic prediction[J]. Ad Hoc Networks, 2020.
- [5] 穆昌. 基于小波变换和极限学习机的网络流量预测模型[J]. 微型电脑应用, 2020, 036(1):138-140.  
MU C. Network traffic prediction model based on wavelet transform and limit learning machine[J]. Microcomputer Applications, 2020, 036(1):138-140.
- [6] FAN J, MU D, LIU Y. Research on network traffic prediction model based on neural network[C]//2019 2nd International Conference on Information Systems and Computer Aided Education(ICISCAE). Piscataway: IEEE, 2019: 554-557.
- [7] ZHANG G, HUANG D. Short-term network traffic prediction with ACD and particle filter[C]//2013 5th International Conference on Intelligent Networking and Collaborative Systems. Piscataway: IEEE, 2013:189-191.
- [8] LI Z, LEI Q, KOUYING X, et al. A novel BP neural network model for traffic prediction of next generation network[C]//2009 Fifth International Conference on Natural Computation. Piscataway: IEEE, 2009:32-38.
- [9] KO T, RAZA S M, BINH D T, et al. Network prediction with traffic gradient classification using convolutional neural networks[C]//2020 14th International Conference on Ubiquitous Information Management and Communication (IMCOM). Piscataway: IEEE, 2020: 1-4.
- [10] MOHORCIC M, SVIGELJ A, KANDUS G, et al. Demographically weighted traffic flow models for adaptive routing in packet-switched non-geostationary satellite meshed networks[J]. Computer Networks the International Journal of Computer & Telecommunications Networking, 2003, 43(2):113-131.
- [11] DONNER A, KISSLING C, HERMENIER R. Satellite constellation networks for aeronautical communication: Traffic modelling and link load analysis[J]. Iet Communications, 2010, 4(13):1594-1606.
- [12] CHEN Q. Traffic prediction based on surrogate model in satellite constellation networks[C]// 2019 12th IFIP Wireless and Mobile Networking Conference (WMNC). Piscataway: IEEE, 2019: 126-130.
- [13] 刑梦来, 王硕, 孙洋洋. 深度学习框架PyTorch快速开发与实战[M]. 北京: 电子工业出版社, 2018.  
XING M L, WANG S, SUN Y Y. Rapid development and practice of deep learning framework PyTorch[M]. Beijing: Publishing House of Electronics Industry, 2018.
- [14] CHEN K, SONG X, HAN D, et al. Pedestrian behavior prediction model with a convolutional LSTM encoder-decoder[J]. Physica A: Statal Mechanics and its Applications, 2020:125132.
- [15] SRIVASTAVA N, HINTON G E, KRIZHEVSKY A, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. Journal of Machine Learning Research, 2014, 15(1): 1929-1958.

## 【作者简介】



**潘成胜**（1962—），男，大连大学通信与网络重点实验室教授，南京信息工程大学电子信息工程学院教授，主要研究方向为一体化网络系统与网络协议、一体化指挥系统的网络理论与技术。



**王羽夫**（1996—），男，大连大学通信与网络重点实验室研究生，主要研究方向为一体化智能网络流量预测技术。



**杨力**（1982—），女，大连大学通信与网络重点实验室负责人，主要研究方向为空间信息网络传输技术、无线通信网络协议理论与方法。